

Ведение DS-проектов. Методология ведения DS-проектов

Алексей Кузьмин
Директор разработки ДомКлик.ру





Алексей Кузьмин

Директор разработки
ДомКлик.ру

О спикере

- Исполнительный директор по исследованию данных ДомКлик.ру
- Руководжу направлением работы с данными и машинного обучения
- Под управлением 9 команд ~60 человек
- Экс-сотрудник ABYY, где занимался распознаванием языков со сложной письменностью
- Выпускник мехмата МГУ



О чём поговорим?



Сегодня на уроке

1

Agile.

Гибкая методология разработки

2

CrispDM.

Методология ведения DS-проектов

3

Смотрим ноутбук.

С небес на землю



Agile. Зачем оно нужно?



О причинах появления процессов

Сложная задача без процесса несёт под собой много рисков:

- человеческий фактор
- отсутствие внешнего контроля
- сложности приёмки–передачи результатов заказчику
- и т. п.



Старый подход – фиксировать всё в ТЗ



Подробно всё проектируем, рисуем интерфейсы, описываем в ТЗ




Кодируем



Тестируем



Сдаём проект, этап заказчику




Проблемы

- Заказчик выпадает из проекта на время его разработки – не видит результат и не может на него оперативно влиять
- Затянутые сроки согласования, сбора ТЗ
- Часто приводит к далеко не идеальному результату



Agile – итеративный подход

Движение к целевому продукту маленькими шагами, каждый из которых несёт капитальный value



Agile

Гибкий подход к разработке ПО.

Лучшие практики



Scrum



XP



TDD, etc.





Гибкость — это не технология, наука или продукт, а культура

Agility is not a technology, science, or product but a culture

Philippe Kruchten



Agile Манифест

- **Люди и взаимодействие** важнее процессов и инструментов
- **Работающий продукт** важнее исчерпывающей документации
- **Сотрудничество с заказчиком** важнее согласования условий контракта
- **Готовность к изменениям** важнее следования первоначальному плану

То есть, не отрицая важности того, что справа, мы всё-таки больше ценим то, что слева



Ценности Agile



Гибкость и простота



Частые релизы



Самоорганизующаяся команда



Больше общения



Гибкость и простота

Agile-процессы готовы к изменениям требований даже на поздних этапах разработки.

Важна простота — искусство увеличения объёма работ, которых удалось избежать



Частые релизы

Наивысший приоритет — удовлетворённость заказчика:

- ранние и периодические поставки ПО
- ПО, работающее и ценное для заказчика

Продолжительность каждой итерации — от пары недель до пары месяцев. Предпочтение отдаётся коротким интервалам



Самоорганизующаяся команда

- Над проектом работают мотивированные люди
- Создаются все условия, атмосфера поддержки и полного доверия
- Самые лучшие архитектуры, требования и дизайны систем создаются самоорганизующимися командами
- Команда самостоятельно организует оптимальный процесс



Больше общения

Потенциальные пользователи системы и разработчики должны работать вместе на протяжении всего проекта.

Самый действенный и эффективный способ обмена информацией как внутри команды разработчиков, так и с внешним миром — непосредственное общение



Agile не работает, плохо работает

- Garbage in – garbage out
- Есть строгий дедлайн
- Команда не самодостаточна для создания продукта: фронт в одной команде, бек – в другой и т. п.



Scrum

Наиболее распространённая практика разработки в Agile.

Ключевые термины

- Product backlog
- Sprint
- Daily scrum



Scrum

Содержит список функциональных единиц системы – user stories, запланированных на следующий релиз

ID	Важн	Название	Описание	Как показать
248	75	Заставка (splash screen)	Как пользователь я хочу видеть заставку, пока приложение открывается	1. Запустить приложение – заставка показ, до появления главного окна



Product Backlog

- Product backlog один на весь релиз
- Им владеет менеджер продукта – product owner
- Он не статичен – записи можно добавлять, удалять, менять им приоритет
- Общедоступен, но поддерживается одним человеком



Спринт (Sprint)

Фаза разработки состоит из нескольких итераций – спринтов. Обычно спринт длится 1–2 недели.

Этапы:

- планирование
- разработка
- демонстрация
- ретроспектива



Sprint Backlog

- Описывает задачи, запланированные командой на спринт
- Задачи — действия, необходимые для реализации запланированной на спринт функциональности
- В описание задачи входит её оценка



Планирование (Sprint Planning)

- Проводится в начале спринта
- Участвует вся команда
- User stories разбиваются на задачи и оцениваются членами команды
- В результате команда подписывается на ту функциональность, на которую хватает времени спринта



Оценка

- Для оценки выбирается единица – идеальный человеко-день или зелёный крокодил
- Перед каждым спринтом следует оценить помехи: focus factor между 0 и 1 и т. д.
- Результаты предыдущего спринта помогают лучше запланировать следующий



Ежедневный скрам (Daily Scrum)

- Проводится каждый день в фиксированное время
- Рекомендуется проводить стоя в течение 10–15 минут
- Если что-то нужно обсудить, назначается время после скрама



Вопросы

Scrum Master спрашивает каждого:



что ты делал?



что ты собираешься делать?



какие были проблемы?



Sprint whiteboard

PLANNED	IN PROGRESS	READY FOR TEST	DONE	BURN-DOWN
				
				UNPLANNED
				



Демонстрация (ревью)

В конце каждого спринта проводится ревью — демонстрация реализованной функциональности.

В демонстрации может участвовать любой человек, задействованный в проекте.

В идеале после каждой демонстрации можно отправлять продукт заказчику.



Ретроспектива спринта

Проводится после каждого спринта, ревью. Участвуют в ней все члены команды.


Цель — осознать:

- что было хорошо?
- что могло бы быть лучше?

Это обсуждение процесса, а не технических сложностей




Crisp DM



Главные вызовы в области больших данных

Основной вызов — как получить
value из больших данных?



**Кто помнит
основные шаги
Crisp DM? =)**



Crisp DM



Business Understanding

- 1** Сбор справочной информации:
- составление бизнес-фона
 - определение бизнес-целей
 - критерии успеха проекта с точки зрения бизнеса



Business Understanding

2

Оценка ситуации:

- инвентаризация ресурсов
- требования, предположения и ограничения
- риски и непредвиденные обстоятельства
- анализ затрат, выгод



Business Understanding

3

Определение целей DS:

- цели DS
- критерии успеха DS

4

Создание плана проекта



Пример

Фаза	Время	Ресурсы	Риски
Business Understanding	1 неделя	Аналитики	Изменение условий
Data Understanding	3 недели	Аналитики	Проблемы с данными, технологиями
Data Preparation	4 недели	DS, DE	Проблемы с данными, технологиями
Modeling	2 недели	DS	Не удастся построить модель
Evaluation	1 неделя	Аналитики	Изменение условий, отсутствие результатов
Deployment	1 неделя	DS, Разработчик	Изменение условий, отсутствие результатов



Готовность к Data Understanding

С точки зрения бизнеса:

- что бизнес надеется получить от этого проекта?
- как будет определяться успех проекта?
- есть бюджет и ресурсы?
- есть ли доступ ко всем данным, необходимым для этого проекта?
- обсуждали ли вы и ваша команда риски и непредвиденные обстоятельства, которые могут возникнуть?
- оправдывают ли результаты вашего анализа затрат, выгод этот проект?



Готовность к Data Understanding

С точки зрения DS:

- как конкретно анализ данных может помочь достичь целей бизнеса?
- есть ли представление о том, какие методы DM могут дать наилучшие результаты?
- как узнать, что результаты являются достаточными для нужд бизнеса?
- как будут поставлены результаты моделирования: отчёт, сервис?
- включает ли план проекта все этапы CRISP-DM?
- обозначены ли риски и зависимости в плане?



Data Understanding

- 1 Соберите имеющиеся данные: собственные, внешние и т. п.
- 2 Опишите данные: количество, значения, связи и т. п.
- 3 Исследуйте данные
- 4 Изучите качество данных: отсутствующие данные, ошибки в данных, плохие метаданные и т. п.



Готовность к Data Preparation

- Все ли источники данных чётко определены и доступны? Известно ли о каких-либо проблемах или ограничениях?
- Определены ли ключевые атрибуты? Эти атрибуты помогли вам сформулировать гипотезы?
- Определён ли размер всех источников данных? Можно ли использовать подмножество данных, где это уместно?
- Рассчитаны базовые статистики для каждого интересующего атрибута?
- Каковы проблемы качества данных для этого проекта?
- Чётко ли определены этапы подготовки данных?



Data Preparation

- Выберите данные: разделите на train, test, выберите признаки
- Очистите данные: заполните пропуски, исправьте ошибки и т. п.
- Расширьте данные: новые признаки и т. п.
- Сохраните данные: подготовьте data frame для обучения модели и сохраните его



Готовность к Modeling

- На основании вашего первоначального исследования смогли ли вы выбрать подходящие подмножества данных для моделирования?
- Эффективно ли вы очистили данные?
- Правильно ли соединены разные наборы данных?
- Задokumentировали ли вы все сделанные шаги по подготовке данных?



Modeling



Выберите метод моделирования



Постройте модель



Оцените модель



Опишите результат



Готовность к Evaluation

- Дала ли модель понятные результаты? Есть ли очевидные несоответствия, которые требуют дальнейшего исследования?
- Исследовано более одного типа модели и результаты сравнены?
- Можно ли поставить модель заказчику?



Evaluation

1

Оцените результаты:

- чётко ли представлены результаты?
- есть ли какие-нибудь новые инсайты?
- может ли модель и результаты быть применимыми к бизнесу?
- какие дополнительные вопросы появились после моделирования?

2

Просмотрите процесс:

- что пошло не так, и как это можно исправить?
- есть ли альтернативные решения, действия, которые могли бы быть выполнены?

3

Определите следующие шаги



Deployment

- 1** Планирование внедрения:
 - для каждой модели создайте план внедрения
 - определите все проблемы внедрения и составьте план на случай непредвиденных обстоятельств
- 2** Планирование мониторинга и технического обслуживания:
 - определите модели и результаты, которые требуют поддержки
 - Как понять, что модель перестала быть актуальной?
 - Что делать в этом случае?
- 3** Проведение итогового обзора проекта



CRISP-DM

Business Understanding/ Бизнес-анализ	Data Understanding/ Анализ данных	Data Preparation/ Подготовка данных	Modeling/ Моделирование	Evaluation/ Оценка решения	Deployment/ Внедрение
Determine Business Objectives/ Определение бизнес-целей	Collect Initial Data/ Сбор данных	Select Data/ Выборка данных	Select Modeling Techniques/ Выбор алгоритмов	Evaluate Results/ Оценка результатов	Plan Deployment/ Внедрение
Assess Situation/ Оценка текущей ситуации	Describe Data/ Описание данных	Clean Data/ Очистка данных	Generate Test Design/ Подготовка плана тестирования	Review Process/ Оценка процесса	Plan Monitoring and Maintenance/ Планирование мониторинга и поддержки
Determine Data Mining Goals/ Определение целей аналитики	Explore Data/ Изучение данных	Construct Data/ Генерация данных	Integrate Data/ Интеграция данных	Determine Next Steps/ Определение следующих шагов	Produce Final Report/ Подготовка отчета
Produkt Project Plan/ Подготовка плана проекта	Verify Data Quality/ Проверка качества данных	Format Data/ Форматирование данных	Build Model/ Обучение моделей	Assess Model/ Оценка качества моделей	Review Project/ Ревью проекта




Кейс. Анализ данных по методологии CrispDM



<https://colab.research.google.com/drive/16hTmqg1PlsQBsa9P8m7nr5zBfbKpL3pt?usp=sharing>



Итоги



Итоги

- 1. Методология Agile** — гибкий подход к разработке продукта небольшими итерациями, несущими value. Процессы крайне важны для успешной работы команды. Они повышают прозрачность, стандартизуют шаги, способствуют более стабильной и качественной работе
- 2. Методология CrispDM** включает в себя 6 этапов работы над задачей: бизнес-анализ, анализ данных, подготовку данных, моделирование, оценку решения, внедрение



Домашнее задание



Домашнее задание

1. Возьмите задачу с винами <https://www.kaggle.com/rajyellow46/wine-quality> и решите её, оформив в виде CrispDM-подхода
 - a. Решение – jupyter notebook на github или colab
2. * Только для тех, кто уже работает над дипломом:
 - a. оформите задачи по дипломной работе в виде этапов CrispDM.
Например, в trello
 - b. пришлите скриншот



Ведение DS-проектов. Методология ведения DS-проектов

Алексей Кузьмин
Директор разработки ДомКлик.ру

